Algoritmy a datové struktury II

TIN061

Ondřej Čepek

Sylabus

Vyhledávání v textu
Toky v sítích
Aritmetické algoritmy
Paralelní aritmetické algoritmy
Základní geometrické algoritmy v rovině
Převoditelnost problémů a třídy časové složitosti
Aproximační algoritmy
Pravděpodobnostní algoritmy a kryptografie
(Dynamické programování)

```
Vyhledávání řetězců v textu
Σ
           konečná abeceda (množina znaků)
Σ*
           množina slov nad abecedou Σ (konečné posloupnosti znaků)
\underline{\text{d\'elka slova}}: u = x_1 x_2 \dots x_m \in \Sigma^*
                                                          length(u) = m
                                                                               (počet znaků ve slově)
skládání (konkatenace) slov u a v :
u = x_1 x_2 ... x_m, v = y_1 y_2 ... y_n
                                                    uv = x_1x_2 \dots x_my_1y_2 \dots y_n
(a samozřejmě length(uv) = length(u) + length(v))
<u>prázdné slovo</u> \epsilon (\forall u \in \Sigma^* platí u\epsilon = \epsilon u = u)
<u>předpona</u> (prefix): u \in \Sigma^* je předponou v \in \Sigma^* pokud \exists w \in \Sigma^*: uw = v
<u>přípona</u> (sufix): u \in \Sigma^* je příponou v \in \Sigma^* pokud \exists w \in \Sigma^*: wu = v
                       pokud w ≠ ε tak se jedná o vlastní předponu (příponu)
Řešená úloha:
           abeceda \Sigma, prohledávaný text x=x_1x_2\,\ldots\,x_n\in\,\Sigma^* a hledané vzorky
           K = \{y_1, y_2, \ldots, y_k\}, \text{ kde } y_p = y_{p,1} \ldots y_{p, \text{length}(p)} \in \Sigma^* \text{ pro } p = 1, \ldots, k
výstup: všechny výskyty vzorků v x, tj. všechny dvojice [i,p] takové, že
            y_p je příponou slova x_1x_2 \dots x_i (1 \le i \le n \text{ a } 1 \le p \le k)
                                                                                                            3
```

Ukážeme, že algoritmus na míru (= konečný automat) lze vyrobit pro libovolný vzorek nebo množinu vzorků, a to tak, že:

• výroba automatu (vyhledávacího stroje) trvá Θ(h · |Σ|)

• vyrobený automat prohlédne text za Θ(n)

• celková práce algoritmu je Θ(n + h · |Σ|)

Algoritmus Aho-Corasick(ová) (1975)

překladač (Algoritmy 2 a 3)

vyhledávací stroj (automat)

interpret (Algoritmus 1)

Vyhledávací stroj pro konečnou abecedu Σ a množinu vzorků K je čtveřice

M = (Q, g, f, out), kde

- 1. $Q = \{0,1, ..., q\}$ je množina stavů
- 2. $g: Q \times \Sigma \to Q \cup \{^{\perp}\}\$ je <u>přechodová funkce</u>, pro kterou platí $\forall \ x \in \Sigma: g(0,x) \in Q$ (symbol $^{\perp}$ znamená "nedefinováno", přechod ze stavu 0 je definován $\forall \ x \in \Sigma$)
- 3. $f: Q \rightarrow Q$ je zpětná funkce, pro kterou platí f(0) = 0 (nastupuje pokud g dá \perp)
- 4. out : $Q \rightarrow P(K)$ je <u>výstupní funkce</u> (pro daný stav vydá podmnožinu vzorků)

Algoritmus 1 (interpret vyhledávacího stroje)

<u>vstup</u>: $x = x_1 \dots x_n \in \Sigma^*$, $K = \{y_1 \dots y_k\}$, M = (Q, g, f, out)

state := 0;

for i := 1 to n do

begin

- (1) while $(g(state,x_i) = \bot)$ do state := f(state);
- (2) state := $g(state, x_i)$;
- (3) for all $y_p \in out(state)$ do Report (i,p)

end

Klíčové vlastnosti vyhledávacího stroje (konečného automatu):

1. přechodová funkce g

graf funkce g (pro definované dvojice bez smyčky ve stavu 0) je ohodnocený strom, pro který

- stav 0 je kořenem stromu
- každá cesta z kořene je ohodnocena nějakou předponou nějakého vzorku z K
- každá předpona každého vzorku z K ohodnocuje cestu z kořene do nějakého (právě jednoho) stavu s ⇒ říkáme, že předpona (slovo) u reprezentuje stav s (speciálně prázdné slovo ε reprezentuje stav 0)
- hloubka stavu s reprezentovaného slovem u je definována jako d(s) = length(u) a pro funkci g (na hranách stromu) platí: d(g(s,x_i)) = d(s) + 1

2. zpětná funkce f

pro každý stav s reprezentovaný slovem u platí, že stav f(s) je reprezentován nejdelší vlastní příponou slova u, která je zároveň předponou nějakého vzorku z K

3. výstupní funkce out

```
pro každý stav s reprezentovaný slovem u a pro každý vzorek y_p \in K platí: y_p \in out(s) tehdy a jen tehdy když je y příponou slova u
```

```
Algoritmus 2 (konstrukce vyhledávacího stroje – 1.fáze)
            K = \{y_1 \dots y_k\}
                                                 {množina vzorků}
vstup:
v\underline{\acute{y}stup}: Q = {0, ...,q}
                                                 {množina stavů vyhledávacího stroje}
            g: Q \times \Sigma \to Q \cup \{\bot\}
                                                 {výstupní funkce splňující Vlastnost 1}
            o: Q \rightarrow P(K)
                                                 {",polotovar" výstupní funkce out}
procedure Enter(y_{p,1} \dots y_{p,m});
                                                 {připojení slova y<sub>p</sub> ke grafu funkce g}
            stav := 0; i:= 1;
begin
            while (i <= m) and (g(stav,y_{p,i}) <> ^{\perp}) do
             begin stav := g(stav, y_{p,i});
                                                             {pohyb po již hotové větvi}
                                                             {posun ve slově y<sub>n</sub>}
                        i := i + 1
             end:
            while (i <= m) do
             begin Q := Q \cup \{q+1\}; q := q+1 \quad \{vytvoření nového stavu\}
                        for all x \in \Sigma do g(q,x) := \bot;
                        g(stav, y_{p,i}) := q;
                                                             {prodloužení větve}
                        stav := q;
                                                             {pokročení do nového stavu}
                        i := i + 1
                                                             {posun ve slově y<sub>n</sub>}
             end;
            o(stav) := \{y_p\}
end:
            {of Enter}
begin
            Q := \{0\}; for all x \in \Sigma do g(0,x) := \bot;
                                                                          {hlavní program}
            \begin{array}{l} \text{for } p := 1 \text{ to } k \text{ do } \text{Enter}(y_p); \\ \text{for all } x \in \Sigma \text{ do if } g(0,x) = \bot \text{ then } g(0,x) = 0 \end{array}
                                                                                                                 8
end.
```

```
Algoritmus 3 (konstrukce vyhledávacího stroje - 2.fáze)
           Q = \{0, \dots, q\}   g : Q \times \Sigma \to Q \cup \{\stackrel{\perp}{\bot}\} 
                                           {množina stavů vyhledávacího stroje}
vstup:
                                           {výstupní funkce splňující Vlastnost 1}
          o: Q \rightarrow P(K)
                                           {"polotovar" výstupní funkce out}
                                           {zpětná funkce splňující Vlastnost 2}
         f: Q \rightarrow Q
<u>výstup</u>:
          out : Q \rightarrow P(K)
                                           {výstupní funkce splňující Vlastnost 3}
vytvoř prázdnou frontu stavů;
f(0) := 0; out(0) := \emptyset;
for all x \in \Sigma do begin
                                           {zpracuje potomky kořene}
                     s := g(0,x);
                     if s <> 0 then
                     begin
                               f(s) := 0; out(s) := o(s);
                                zařaď s na konec fronty
                     end
                  end;
while fronta není prázdná do
          r := první prvek z fronty (a vyřaď r z fronty);
begin
          for all x \in \Sigma do if g(r,x) \iff \bot then {zpracuje potomky uzlu r}
                     s := g(r,x); t := f(r);
          begin
                     while g(t,x) = \bot then t := f(t);
                     f(s) := g(t,x); out(s) := o(s) \cup out(f(s));
                     zařaď s na konec fronty
          end
                                                                                                   9
end
```

Algoritmus Knuth-Morris-Pratt

- zjednodušená verze algoritmu Aho-Corasick(ová) pro vyhledávání jediného vzorku
- kratší a snadněji pochopitelný popis
- (mírně) lepší asymptotická složitost ($\Theta(n+h)$ místo $\Theta(n+h\cdot|\Sigma|)$)
- graf přechodové funkce g není strom ale řetězec, což umožňuje g explicitně vůbec nepoužívat (zde je ta úspora ve složitosti preprocessingu, protože g má h $\cdot |\Sigma|$ přechodů), funkce g je používána pouze implicitně
- zpětná funkce f se zde nazývá <u>prefixová</u> funkce a protože v případě jediného vzorku odpovídá číslo stavu <u>délce</u> prefixu daného vzorku, který je daným stavem reprezentován, tak má f jednoduší definici:
- f(s) je délka nejdelší vlastní přípony slova reprezentovaného stavem s (toto slovo je prostě předpona délky s daného vzorku), která je zároveň předponou (daného vzorku)
- výstupní funkce je triviální, ve stavu h hlásí výskyt (jediného) vzorku, jinde nic

```
procedura Prefix (nahrazuje Algoritmy 2 a 3)
vstup: K = \{y\}
                                {jediný vzorek}
<u>výstup:</u> f: Q \rightarrow Q
                                {prefixová funkce}
f(1) := 0;
t := 0;
for q := 2 to h do
          while (t > 0) and (y_{t+1} <> y_q) do t := f(t);
begin
           if (y_{t+1} = y_q) then t := t + 1;
           f(q) := t
end
                           Algoritmus KMP (nahrazuje Algoritmus 1)
<u>vstup</u>: x = x_1 \dots x_n \in \Sigma^*, K = \{y\}, prefixová funkce f
state := 0;
for i := 1 to n do
begin
           (1) while (state > 0) and (y_{state+1} \ll x_i) do state := f(state);
           (2) if y_{\text{state+1}} = x_i then state := state + 1;
           (3) if (state = h) then begin Report (i);
                                            state := f(state)
                                     end
                                                                                                  11
end
```

Toky v sítích

Síť: orientovaný graf G = (V,E) se dvěma vybranými vrcholy s,t (zdroj a stok) a kladnou kapacitou c(u,v) na každé hraně (u,v) ∈ E. Kapacita je dodefinována i pro ostatní dvojice vrcholů: c(u,v) = 0 pokud (u,v) ∉ E.

<u>Tok</u>: je funkce f : V × V → R splňující následující tři vlastnosti:

```
1. (Symetrie) \forall u,v \in V: f(u,v) = -f(v,u)
```

- 2. (Kapacita) $\forall u,v \in V : f(u,v) \le c(u,v)$
- 3. (Zachování toku) \forall $u \in V \{s,t\}$: $\Sigma_{v \in V}$ f(u,v) = 0 (jako Kirkhoffův zákon pro el.proud) Pokud f(u,v) > 0 tak říkáme, že máme (nenulový) tok z u do v. Pokud f(u,v) = c(u,v) tak říkáme, že je hrana (u,v) saturovaná. Velikost toku f značíme |f| a je to celkový čistý tok ze zdroje, tj. $|f| = \Sigma_{v \in V}$ f(s,v).

Problém: hledání maximálního toku, tj. toku maximální velikosti.

<u>Řez</u>: v kontextu toků je <u>řez</u> dvojice množin vrcholů X,Y taková, <u>že X</u> \cup Y = V, s \in X, t \in Y. <u>Kapacita řezu X,Y je součet kapacit hran jdoucích přes řez, tj. c(X,Y) = $\Sigma_{u \in X, v \in Y}$ c(u,v). <u>Minimální řez je řez s minimální kapacitou. Tok přes řez X,Y je součet toků pohranách jdoucích přes řez, tj. f(X,Y) = $\Sigma_{u \in X, v \in Y}$ f(u,v).</u></u>

<u>Lemma 1</u>: Pro každý tok f a řez X,Y platí, že tok přes řez X,Y je roven velikosti toku, tj. f(X,Y) = |f|.

Díky Lemma 1 a triviálnímu faktu, že $f(X,Y) \le c(X,Y)$ pro každý řez X,Y (díky kapacitnímu omezení) platí, že velikost maximálního toku je nejvýše rovna kapacitě minimálního řezu. Ukážeme, že zde vždy platí rovnost.

Reziduální kapacita toku f je funkce r : $V \times V \rightarrow R$ definovaná předpisem

$$r(u,v) = c(u,v) - f(u,v)$$

Reziduální graf pro f: orientovaný graf R = (V,E'), kde $(u,v) \in E'$ tehdy a jen tehdy, když platí r(u,v) > 0 a hodnotu r(u,v) pak nazýváme kapacitou hrany (u,v) v reziduálním grafu.

Zlepšující cesta pro f: libovolná cesta p z s do t v grafu R. Reziduální kapacita r(p) zlepšující cesty p je rovna minimálnímu r(u,v) z hran (u,v) na cestě p. Velikost toku můžeme zvýšit až o r(p) zvýšením toku (o stejné množství) na všech hranách cesty p. (Poznámka: při zvýšení f(u,v) je nutné proporčně snížit f(v,u) pro zachování symetrie.)

Věta (o max.toku a min.řezu): Následující podmínky jsou ekvivalentní

- 1. tok f je maximální tok
- 2. pro f neexistuje zlepšující cesta
- 3. platí |f| = c(X,Y) pro nějaký řez X,Y

13

Věta o max.toku a min.řezu dává návod jak zkonstruovat maximální tok postupným zlepšováním.

<u>Metoda zlepšující cesty</u>: Začni s nulovým tokem a opakuj následující krok, dokud není dosaženo toku, pro který neexistuje zlepšující cesta.

<u>Zlepšující krok</u>: Pro aktuální tok f najdi zlepšující cestu p a zvyš velikost toku pomocí zvýšení toku na cestě p o r(p).

<u>Jednoduchá implementace (Ford a Fulkerson)</u>: Najdi libovolnou zlepšující cestu pomocí prohledání grafu R (libovolným algoritmem na prohledávání orientovaných grafů).

Poznámky:

- ze znalosti maximálního toku můžeme v čase 0(m) zkonstruovat minimální řez (viz důkaz Věty o max.toku a min.řezu)
- pokud jsou kapacity iracionální čísla, tak nemusí jednoduchá implementace metody zlepšující cesty skončit po konečném počtu kroků, velikost toku sice vždy konverguje ale nemusí konvergovat k velikosti maximálního toku
- pokud jsou kapacity racionální čísla, tak lze úlohu převést na ekvivalentní úlohu s celočíselnými kapacitami
- pokud jsou kapacity celočíselné, tak každý zlepšující krok zvýší velikost toku alespoň o
 jedna, a tudíž metoda končí po nejvýše |f*| zlepšujících krocích, navíc je zkonstruovaný
 maximální tok celočíselný (na každé hraně)

"Ideální verze" metody zlepšující cesty:

<u>Lemma 2</u>: Vždy existuje posloupnost nejvýše m zlepšujících cest, pomocí nichž lze zkonstruovat maximální tok.

Implementace s maximálním zlepšením (Edmonds a Karp): V každém kroku najdi mezi všemi zlepšujícími cestami tu s maximální reziduální kapacitou.

<u>Lemma 3</u>: Nechť f je libovolný tok a nechť f* je maximální tok na G. Potom velikost maximálního toku na reziduálním grafu R pro tok f je $|f^*| - |f|$.

<u>Věta</u>: Počet zlepšujících kroků při implementaci s maximálním zlepšením je 0(m log c) kde c je maximální kapacita nějaké hrany.

Poznámky:

- toto už je polynomiální počet kroků vzhledem k velikosti dat
- odhad platí jen když jsou kapacity celočíselné (a metoda v tom případě samozřejmě opět konverguje k maximálnímu toku)
- zlepšující cestu s maximální reziduální kapacitou lze najít v polynomiálním čase pomocí modifikovaného Dijkstrova algoritmu (pro tzv. bottleneck problém), kde délku cesty neměříme součtem délek hran ale délkou nejkratší hrany (detaily nebudeme zkoumat, další probírané algoritmy jsou lepší)
- nyní bude cílem implementace jejíž časová složitost bude záviset jen na n a m

<u>Implementace s nejkratším zlepšením (Edmonds a Karp)</u>: V každém kroku najdi mezi všemi zlepšujícími cestami tu nejkratší, tj. zlepšující cestu s minimálním počtem hran.

<u>Věta</u>: Počet zlepšujících kroků při implementaci s nejkratším zlepšením je 0(nm) a metoda zlepšující cesty běží v tomto případě v čase 0(nm²).

<u>Definice</u>: Nechť f je tok a R je reziduální graf pro f. Úroveň u(x) vrcholu x v R je délka nejkratší cesty z s do x v R. Úrovňový graf U pro tok f je podgraf grafu R, který obsahuje pouze vrcholy dosažitelné z s a pouze hrany (x,y) pro které u(y) = u(x) + 1.

<u>Pozorování</u>: Graf U lze zkonstruovat v čase O(m) pomocí BFS a pokud existuje zlepšující cesta, tak U obsahuje všechny nejkratší zlepšující cesty.

Dalšího zlepšení lze dosáhnout tím, že místo zvyšování toku po jednotlivých nejkratších zlepšujících cestách použijeme všechny nejkratší zlepšující cesty "najednou".

 $\underline{\text{Definice}}\text{: Tok f na grafu U se nazývá blokující tok, pokud každá cesta z s do t v grafu U (v původním U, tj. ne pozměněném tokem f) obsahuje saturovanou hranu.}$

Algoritmus (Dinic): Začni s nulovým tokem a opakuj následující (blokující) krok dokud existuje zlepšující cesta, tj. dokud je vrchol t dosažitelný v aktuálním úrovňovém grafu:

(Blokující) krok: Najdi blokující tok f' na úrovňovém grafu U definovaném pomocí aktuálního toku f. Nahraď tok f tokem f +f' který je definován předpisem

$$(f + f')(x,y) = f(x,y) + f'(x,y)$$

<u>Lemma 4</u>: Dinicův algoritmus zastaví po nejvýše n – 1 blokujících krocích.

<u>Jak hledat blokující tok</u>: Existuje několik metod, my probereme tu původní Dinicovu, která je nejprimitivnější.

Idea: Najdi cestu z s do t v U (pomocí DFS), zvyš po ní tok tak, aby nějaká hrana na nalezené cestě byla saturována. Z U vyhoď všechny nově saturované hrany a postup opakuj dokud je t dosažitelné z s v grafu U.

<u>Formální popis</u>: Začni s nulovým tokem a jdi na <u>Inicializaci</u>. Aktuálně prohlížený vrchol budeme označovat x a p bude zlepšující cesta z s do x.

Inicializace: Definuj p = [s] a x = s. Jdi na Vpřed.

Vpřed: Pokud z x nevede v U žádná hrana jdi na Vzad. Jinak vezmi libovolnou hranu (x,y), prodluž p o vrchol y a do x dosaď y (posuň aktuální vrchol). Pokud platí $y \neq t$ tak opakuj Vpřed, pokud y = t jdi na Zlepši.

Vzad: Pokud x = s tak zastav (neexistuje zlepšující cesta do t). Pokud $x \neq s$ tak nechť (v,x) je poslední hrana na p. Zkrať p o vrchol x a hranu (v,x) odstraň z U. Do x dosaď y (posuň aktuální vrchol) a jdi na Vpřed.

Zlepši: Nechť d = $min\{c(x,y) - f(x,y) \mid (x,y) \text{ je hrana v p}\}$. Přidej d k toku na všech hranách cesty p, odstraň z U všechny nově saturované hrany a jdi na Inicializace.

<u>Věta</u>: Dinicův algoritmus nalezne blokující tok v úrovňovém grafu U v čase 0(nm) a maximální tok ve vstupním grafu G v čase $0(n^2m)$.

17

Metoda "preflow-push"

<u>Definice:</u> Předtok (preflow) je funkce $f: V \times V \to R$ splňující stejně jako tok podmínku symetrie a kapacity na každé hraně, ale která místo podmínky zachování toku má pro každý vrchol u (kromě zdroje s) podmínku $e(u) = \sum_{v \in V} f(u,v) \ge 0$, kde e(u) je přebytek (exces) ve vrcholu u. Vrchol u různý od s a t se nazývá aktivní pokud má kladný přebytek (e(u) > 0).

<u>Definice:</u> Nechť f je předtok a R reziduální graf pro f. Pak funkce $h: V \to N$ je výšková funkce vzhledem k f pokud

- h(s) = |V|
- h(t) = 0
- $\forall (u,v) \in R : h(u) \le h(v) + 1$

Pokud pro hranu $(u,v) \in R$ platí h(u) = h(v) + 1, tak se (u,v) nazývá přípustná.

Inicializace (pro generický preflow-push algoritmus):

- 1. Vynuluj všechna h(u), e(u) a f(u,v).
- 2. Dosaď h(s) := |V|.
- 3. Pro všechny sousedy u zdroje s dosaď
 - f(s,u) := c(s,u) a f(u,s) := -c(s,u)

• e(u) := c(s,u)

Platí po inicializaci: f je předtok a h je výšková funkce vzhledem k f.

Algoritmus používá dvě základní akce :

ZATLAČ(u) (neboli PUSH(u))

- POUŽITÍ: pokud je u aktivní (e(u) > 0) a existuje přípustná hrana (u,v) v R, tj. hrana splňující r(u,v) > 0 a h(u) = h(v) + 1.
- AKCE: pošli d(u,v) = min {e(u), r(u,v)} jednotek toku z u do v a příslušně aktualizuj f(u,v), f(v,u), e(u) a e(v).

<u>Definice</u>: ZATLAČ(u) je saturující, pokud se hrana (u,v), po které je posílán tok, stane saturovanou (což nastane pokud d(u,v) = r(u,v)) a nesaturující v opačném případě (tj. pokud d(u,v) = e(u) < r(u,v)).

ZVEDNI(u) (neboli LIFT(u))

- POUŽITÍ: pokud je u aktivní (e(u) > 0) a neexistuje přípustná hrana (u,v) v R.
- AKCE: $h(u) := 1 + min \{h(v) \mid (u,v) \lor R\}$

Algoritmus (generický preflow-push algoritmus):

- Inicializace
- Dokud existuje aktivní vrchol tak nějaký vyber (nechť je to u) a uplatni buď ZATLAČ(u) nebo ZVEDNI(u).

19

Lemma 1: Pro každý vrchol u během celého běhu algoritmu platí:

- h(u) nikdy neklesne
- každé ZVEDNI(u) zvýší h(u) alespoň o jedna

<u>Lemma 2</u>: Funkce h zůstává během celého běhu algoritmu výškovou funkcí vzhledem k aktuálnímu (před)toku f.

<u>Lemma 3</u>: Během celého běhu algoritmu platí, že v R neexistuje cesta z s do t.

Věta (korektnost algoritmu):

Pokud algoritmus skončí, tak f (v tom okamžiku) reprezentuje maximální tok.

Časová složitost: Za celou dobu běhu algoritmus udělá:

- O(|V|²) zvednutí
- O(|V||E|) saturujících zatlačení
- O(|V|²|E|) nesaturujících zatlačení

což při implementaci potřebující O(|V|) na každé zvednutí a O(1) na každé zatlačení dává celkovou složitost algoritmu $O(|V|^2|E|)$.

 $\frac{\text{Poznámka:}}{\text{O}(|V||E|\log(|V|^2 / |E|))}, \text{což je asymptoticky nejrychlejší známý algoritmus [Goldberg, Tarjan 88]}.$

Násobení polynomů

Dva způsoby reprezentace polynomů:

1. Pomocí vektoru koeficientů (zde vektor komplexních čísel)

$$A(x) = a_{n-1}x^{n-1} + a_{n-2}x^{n-2} + \dots + a_1x^1 + a_0x^0$$

A(x) je polynom s mezí stupně n, $a_0 \dots a_{n-1}$ jsou jeho koeficienty a A(x) je polynom stupně k pokud a_k je jeho nejvyšší nenulový koeficient

- Součet dvou polynomů: Θ(n)
- Výpočet hodnoty v bodě: Θ(n) pomocí Hornerova schématu
- Součin dvou polynomů: Θ(n²) (konvoluce příslušných vektorů koeficientů)
- 2. Pomocí funkčních hodnot v bodech

$$\{(x_0,y_0), (x_1,y_1), \dots, (x_{n-1},y_{n-1})\}$$

Takto lze jednoznačně reprezentovat libovolný polynom A(x) s mezí stupně n, a to libovolnou n-ticí ve které jsou všechny x_i po dvou různé a $y_i = A(x_i)$ pro každé i.

- Výpočet hodnoty v bodě: mimo zadané body nelze bez konverze k reprezentaci pomocí vektoru koeficientů
- Součet dvou polynomů: Θ(n)
- Součin dvou polynomů: Θ(n) ale POZOR potřebujeme 2n bodů

21

Konverze mezi oběma reprezentacemi

- 1. Koeficienty → Dvojice (evaluace): Θ(n²) pomocí Hornerova schématu (i pro 2n bodů), ale lze v Θ(n log n) když body pro výpočet funkčních hodnot vybrány "chytře"
- 2. Dvojice \to Koeficienty (interpolace): obecně $\Theta(n^3)$ Gaussovou eliminací nebo $\Theta(n^2)$ pomocí Lagrangeovy formule (nebudeme probírat), ale lze v $\Theta(n \log n)$ když známe funkční hodnoty v "chytře" vybraných bodech

Násobení polynomů v ⊖(n log n)

Chytře vybranými body budou 2n-té komplexní odmocniny čísla 1, které budeme značit

$$W_{2n}^{0}, W_{2n}^{1}, \dots, W_{2n}^{2n-1}$$

Násobení pro vstup $a_0 \dots a_{n-1}$ a $b_0 \dots b_{n-1}$ (dva vektory koeficientů polynomů s mezí stupně n) pak bude probíhat následovně:

- 1. Doplníme oba vektory n nulami na posloupnosti délky 2n-1 (to je nová mez stupně)
- 2. Evaluace: spočítáme funkční hodnoty A(x) i B(x) ve všech 2n odmocninách čísla 1
- 3. Násobení: bod po bodu C(x) = A(x)B(x) ve všech 2n odmocninách čísla 1
- 4. Interpolace: spočítáme vektor koeficientů polynomu C(x) zadaného 2n funkčními hodnotami (ve všech odmocninách čísla 1)

Kroky 1 a 3 trvají $\Theta(n)$ a kroky 2 a 4 trvají $\Theta(n \log n)$ pokud jsou implementovány Rychlou Fourierovou Transformací (FFT)

Vlastnosti n-tých odmocnin čísla 1 v komplexním oboru

<u>Krátící lemma</u>: Pokud n≥0, k≥0 a d>0 potom $w_{dn}^{dk} = w_n^k$.

Důsledek: Pro n>0 sudé platí $w_n^{n/2} = w_2^1 = -1$.

<u>Půlící lemma</u>: Pro n>0 sudé platí, že druhé mocniny n komplexních n-tých odmocnin čísla 1 jsou rovny n/2 komplexním n/2-tým odmocninám čísla 1 (každá zastoupena 2x).

Součtové lemma: Pokud n≥0 a k>0 a k není dělitelné n potom $\sum_{j=0}^{n-1} (w_n^k)^{j} = 0$.

Diskrétní Fourierova Transformace (DFT)

Polynom $A(x) = a_{n-1}x^{n-1} + a_{n-2}x^{n-2} + ... + a_1x^1 + a_0x^0$ s mezí stupně n zadaný vektorem koeficientů chceme reprezentovat pomocí funkčních hodnot v n komplexních n-tých odmocninách čísla 1, tj. chceme spočítat hodnoty

$$y_k = A(w_n^k)$$
 pro $k = 0, 1, ..., n-1$.

Vektor y (funkčních hodnot) se nazývá DFT vektoru a (koeficientů), píšeme $y = DFT_n(a)$.

Transformace opačným směrem se nazývá inverzní DFT a píšeme a = DFT_n-1(y).

Poznámka: pokud n je mezí stupně obou vstupních polynomů (které chceme vynásobit), tak zde vlastně pracujeme s n' = 2n, ale pro jednoduchost značení budeme používat n (navíc na asymptotickou složitost nemá vliv zda používáme n nebo n').

Rychlá Fourierova Transformace (FFT)

Algoritmus využívající strategii "rozděl a panuj" pro spočítání $DFT_n(a)$, rozdělením A(x) pomocí koeficientů lichého a sudého stupně na dva polynomy s mezí stupně n/2:

$$\begin{split} A^s(x) &= a_0 + a_2 x + a_4 x^2 + \ldots + a_{n-2} x^{n/2-1} \\ A^l(x) &= a_1 + a_3 x + a_5 x^2 + \ldots + a_{n-1} x^{n/2-1} \end{split}$$

Nyní zjevně platí $A(x) = A^s(x^2) + x A^l(x^2)$ (vztah označme ($^{\mathbf{z}}$)), takže úloha spočítat funkční hodnoty polynomu A(x) v bodech $w_n^0, w_n^1, \dots, w_n^{n-1}$ je převedena na úlohu

- spočítat funkční hodnoty polynomů $A^s(x)$ a $A^l(x)$ (s mezí stupně n/2) v bodech $(w_n^0)^2$, $(w_n^1)^2$, ..., $(w_n^{n-1})^2$ (což je ale jen n/2 různých bodů díky půlícímu lemmatu), tj. místo původní úlohy vyřešit dvakrát zcela stejnou úlohu na polovičních datech
- zkombinovat výsledky podle vztahu (^x) což zabere čas ⊕(n)

Celkový čas T(n) pro FFT délky n je $T(n) = 2T(n/2) + \Theta(n)$ a tedy $T(n) = \Theta(n \log n)$.

<u>Lemma</u> Nechť V_n je Vandermondeho matice pro $w_n^{\ 0},\ w_n^{\ 1},\ \dots,\ w_n^{n-1}.$ Pak prvek na pozici (j,k) v inverzní matici $V_n^{\ -1}$ je roven $w_n^{\ -kj}/n.$

Tím pádem lze i inverzní DFT počítat pomocí FFT, protože spočítání koeficientů polynomu zadaného funkčními hodnotami $y_0, y_1, \ldots, y_{n-1}$ je to samé jako spočítání funkčních hodnot polynomu Y(x)/n s koeficienty $y_0/n, y_1/n, \ldots, y_{n-1}/n$ a sice v bodech $w_n^0, w_n^{-1}, \ldots, w_n^{-(n-1)}$

Implementace FFT

1. Rekurzivní implementace (přímý přepis algoritmu)

```
REC-FFT(a);
n := length(a);
                                        {n je mocnina dvojky}
if n=1 then return a;
                                        {dno rekurze}
p := e^{2\pi i / n}:
                                        {principiální kořen w<sub>n</sub>¹ = generátor ostatních kořenů}
w := 1;
                                        {aktuálně zpracovávaný kořen, začíná se s w = w_n^0}
a^{s} := (a_{0}, a_{2}, ..., a_{n-2});
                                        {příprava vstupních dat pro rekurzi}
a^{l} := (a_{1}, a_{3}, ..., a_{n-1});
y^s := REC-FFT(a^s);
y^{l} := REC-FFT(a^{l});
                                        {vlastní rekurze}
for k := 0 to (n/2 - 1) do
       y_k := y_k^s + w y_k^l;
                                        {spočítání hodnoty A(w) v aktuálním kořeni w = w_n^k}
                                        {spočítání hodnoty A(w) v protilehlém kořeni w<sub>n</sub>k+n/2}
       y_{k+n/2} := y_k^s - w y_k^l;
       w := w p;
                                        {posun na další kořen, tj. na w<sub>n</sub><sup>k+1</sup>}
return y
```

<u>Časová složitost</u>: je vidět, že $T(n) = 2T(n/2) + \Theta(n)$ a tedy $T(n) = \Theta(n \log n)$, protože práce mimo rekurzi je zjevně $\Theta(n)$.

25

2. Iterativní implementace (hlavní idea)

vznikne následujícími úpravami rekurzívní implementace

- tělo for cyklu z rekurzivní implementace nahradíme "butterfly" operací
- strom rekurze procházíme po patrech odspodu
- iniciální pořadí listů stromu pro start algoritmu získáme bitovou reverzí

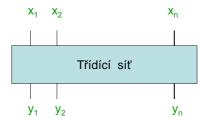
<u>Časová složitost</u>: na každém patře stromu je voláno právě n/2 butterfly operací, tj. na každém patře je celková práce $\Theta(n)$, což dohromady s faktem, že hloubka stromu je přesně log n dává časovou složitost algoritmu $\Theta(n \log n)$.

- 3. Paralelní implementace (hlavní idea)
- butterfly operace na stejném patře stromu se provádějí paralelně
- algoritmus lze realizovat hardwarově vhodným zřetězením butterfly obvodů do sítě, která má "šířku" n a "hloubku" log n

<u>Časová složitost</u>: na každém patře nyní trvá (s použitím n/2 "procesorů") veškerá práce O(1), takže celková časová složitost je Θ(log n).

Třídící sítě

Třídící síť je obvod který má n vstupů z hodnotami z nějakého lineárně uspořádaného typu (tj.každé dvě hodnoty jsou porovnatelné) a n výstupů, na kterém jsou vstupní hodnoty setříděné (bez ohledu na to v jakém pořadí přišly na vstup).



Tento obvod obsahuje jediný typ hradla a sice komparátor, což je hradlo se dvěma vstupy x_1 a x_2 a dvěma výstupy y_1 a y_2 , pro které platí y_1 =min $\{x_1,x_2\}$ a y_2 =max $\{x_1,x_2\}$.

Formální definice třídící sítě:

- K = {K₁, K₂, ..., K_s} je množina komparátorů, s se pak nazývá velikost sítě
- O = { $(k,i) \mid 1 \le k \le s, 1 \le i \le 2$ } je množina výstupů (k je číslo komparátoru a i výstupu)
- I = { $(k,i) \mid 1 \le k \le s, 1 \le i \le 2$ } je množina vstupů
- C = (K, f) je třídící síť, kde $f : O \rightarrow I$ je částečné prosté zobrazení

Podmínka acyklicity sítě:

Požadujeme aby orientovaný graf G = (K,E) kde $(K_u,K_v) \in E$ pokud existují i a j takové, že f(u,i) = (v,j), byl acyklický.

Rozdělení komparátorů do hladin:

- Definujme $L_1 = \{ K_i \mid K_i \text{ má v G vstupní stupeň nula} \}$ (L_1 je neprázdná díky acyklicitě)
- Nechť jsou definovány L_1, L_2, \ldots, L_h , kde $L = L_1 \cup L_2 \cup \ldots \cup L_h \not\subset K$. Pak definujme $L_{h+1} = \{ \ K_i \ | \ K_i \ má \ v \ G \setminus L \ vstupní \ stupeň \ nula \} \ (L_{h+1} \ je \ neprázdná \ díky \ acyklicitě)$
- Počet hladin značíme d a nazýváme hloubkou sítě

Práce sítě:

- čas 0 : definovány vstupy sítě (kam patří vstupy všech komparátorů v L₁)
 pracují komparátory v L₁
- čas 1 : definovány vstupy všech komparátorů v L₂
 pracují komparátory v L₂
- čas d-1 : definovány vstupy všech komparátorů v L_d
 pracují komparátory v L_d
- čas d : definovány všechny výstupy sítě

28

<u>Pozorování</u>: časová složitost třídění odpovídá hloubce sítě (to je tedy klíčový parametr)

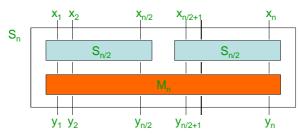
Topologicky jiná reprezentace sítě:

- "dráty" ze vstupu x_i do výstupu y_i nakresleny jako přímky
- jednotlivé komparátory "roztaženy" mezi příslušné "dráty"
- každá síť jde takto překreslit
- počtu vstupů/výstupů (drátů) říkáme šířka sítě

Merge-Sort implementovaný třídící sítí

Chceme setřídít x_1, x_2, \ldots, x_n (předpokládáme že n je mocnina dvojky)

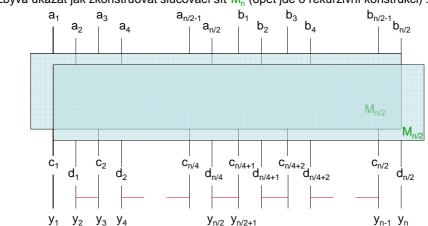
Realizujeme to sítí $\mathbb{S}_{\mathbf{n}}$, která je rekurzivně definována následujícím obrázkem



kde M_n je slučovací (slévací) síť šířky n (rekurze se zastaví pro n=2)

29

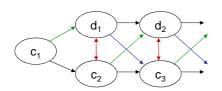
Zbývá ukázat jak zkonstruovat slučovací síť M_{n} (opět jde o rekurzivní konstrukci) :

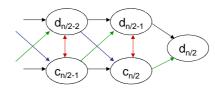


Liché členy obou setříděných posloupností jsou vstupem jedné kopie $M_{n/2}$ a sudé členy jsou vstupem druhé kopie $M_{n/2}$. Navíc jsou výstupy obou sítí propojeny jednou hladinou komparátorů dle obrázku (červené komparátory). Rekurze se opět zastaví pro n=2.

 $\begin{array}{lll} \text{Pro vstup plati:} & a_1 \leq a_2 \leq \ldots \leq a_{n/2} \ \ \text{a} \ \ b_1 \leq b_2 \leq \ldots \leq b_{n/2} \\ \text{Indukční předpoklad:} & c_1 \leq c_2 \leq \ldots \leq c_{n/2} \ \ \text{a} \ \ d_1 \leq d_2 \leq \ldots \leq d_{n/2} \\ \end{array}$

Dokážeme, že: $y_1 \le y_2 \le ... \le y_n$





Černé nerovnosti (šipky) víme, zelené nerovnosti a modré nerovnosti (šipky) dokážeme. Bez ohledu to, jak dopadne porovnání jednotlivými červenými komparátory, budou šipky generovat lineární uspořádání, které bude správným uspořádáním výstupních hodnot.

Hloubka a velikost třídící sítě šířky n = 2k

1.Slučovací síť M_n

má hloubku (počet hladin) $d(M_n) = log_2 n$

a velikost (počet komparátorů) $s(M_n) = n/2 \log_2(n/2) + 1$

2. Třídící síť S_n

má hloubku (počet hladin) $d(S_n) = 1/2 \log_2 n (\log_2 n + 1)$

a velikost (počet komparátorů) $s(S_n) = 1/4 \text{ n } \log_2 n (\log_2 n - 1) + (n-1)$

31

Dolní odhad složitosti třídění pomocí transpozičních sítí

Transpoziční síť = síť složená pouze z komparátorů (zcela libovolně umístěných)

⇒ třídící síť je tedy speciálním případem transpoziční sítě

<u>Lemma 1</u> Každá transpoziční síť dává pro vstup x_1, x_2, \ldots, x_n na výstupu nějakou permutaci Π vstupních hodnot, tedy dává na výstupu $x_{\Pi(1)}, x_{\Pi(2)}, \ldots, x_{\Pi(n)}$.

<u>Důkaz</u> Zcela zřejmý, síť nemůže udělat nic jiného než nějak zpřeházet vstupy.

<u>Lemma 2</u> Nechť C je třídící síť šířky n. Pak je pro C dosažitelných všech n! permutací.

<u>Lemma 3</u> Nechť C je transpoziční síť šířky n a nechť p je počet dosažitelných permutací pro C. Potom platí

 $p \le 2^{s(C)}$.

Důsledek Pokud je C třídící síť tak

 $n! \le 2^{s(C)}$

a tím pádem má C velikost $s(C) = \Omega(n \log n)$ a hloubku $d(C) = \Omega(\log n)$.

Aritmetické sítě

- definice je podobná jako u třídících sítí, zcela stejně je definována šířka (počet vstupů, tj. vstupních drátů), velikost (počet hradel) a hloubka (počet hladin) sítě
- časová složitost výpočtu opět odpovídá hloubce sítě
- dráty zde přenášejí jen hodnoty 0 a 1 (tj. jeden bit informace, ne více bitů jako v případě třídících sítí)
- hradla jsou logická hradla, typicky unární hradlo NOT a binární hradla AND, OR a XOR
- drát z jednoho výstupu může jít do více vstupů ("rozvětvit se"), musí být ovšem stále zachována acyklicita sítě

Sčítač (full adder)

Sčítač je obvod mající tři vstupy x,y,z a dva výstupy c,s, jehož funkci lze chápat tak, že x a y jsou bity dvou binárních čísel ve stejném řádu, z je přenos z nižšího řádu, s příslušný bit součtu x+y a c je přenos do vyššího řádu

z tabulky pro výpočet s a c plyne, že s = parita(x,y,z) a c = majorita(x,y,z)

Sčítání dvou n-bitových binárních čísel

- n bude mocnina dvojky, sčítat budeme čísla $a = (a_{n-1}, \ldots, a_0)$ a $b = (b_{n-1}, \ldots, b_0)$
- ukážeme dva obvody: pro klasické sčítání a pro carry-lookahead sčítání

33

Obvod pro klasické sčítání

- sčítání je realizováno kaskádou n sčítačů, kde sčítač v řádu i čeká na přenos (carry bit) od sčítače řádu i –1 a posílá svůj carry bit do sčítače řádu i +1
- síť má velikost ⊖(n) a hloubku také ⊖(n)

Obvod pro carry-lookahead sčítání

zrychlení je založeno na myšlence, že v některých případech lze přenos z i-tého řádu určit jen na základě a_i a b_i (které jsou známy od začátku) a není potřeba čekat na přenos z nižšího řádu (jehož spočítání může trvat dlouho)

- v případě, že $a_i = b_i = 0$ tak $c_{i+1} = 0$ (bez ohledu na hodnotu c_i) \rightarrow kill carry bit c_{i+1}
- v případě, že $a_i = b_i = 1$ tak $c_{i+1} = 1$ (bez ohledu na hodnotu c_i) \rightarrow generate carry bit c_{i+1}
- v případě a_i ≠ b_i platí, že c_{i+1} = c_i → propagate carry bit ci do carry bitu c_{i+1}

tím je definován carry status každého řádu $i \in \{1, \dots, n\}$, který označíme proměnnou x_i , jejíž hodnotu z množiny $\{k, p, g\}$ lze snadno spočítat z a_{i-1} a b_{i-1} podle uvedených pravidel

uvažujme dva za sebou napojené sčítače jako jeden obvod s jedním vstupním a jedním výstupním carry bitem: carry status kombinovaného obvodu lze spočítat z (k,p,g) obou zúčastněných sčítačů

tím je definován binární carry status operátor ⊗ na množině {k,p,g}, který je asociativní (bez důkazu, stačí rutinní rozbor všech 27 případů)

pokud dodefinujeme $x_0 = y_0 = k$, pak pro každý řád $i \in \{1, ..., n\}$ lze definovat proměnnou

$$y_i = y_{i-1} \otimes x_i = x_0 \otimes x_1 \otimes ... \otimes x_i$$

kterou lze chápat jako i-tý prefix součinu $x_0 \otimes x_1 \otimes ... \otimes x_n$

Lemma Pro i = 0, 1, ..., n platí

- 1. pokud $y_i = k \text{ tak } c_i = 0$
- 2. pokud $y_i = g tak c_i = 1$
- 3. případ y_i = p nenastane

<u>Důsledek</u> Pokud jsou známa všechna y_i tak už lze součet spočítat v O(1) pomocí n paralelně běžících sčítačů (pokud ztotožníme k = 0 a g = 1, což lze protože p nemůže nastat), takže problém sčítání se tímto převádí na problém výpočtu všech prefixů.

Sčítací obvod sestává z n KPG obvodů a prefixového obvodu. Každý KPG obvod je využit dvakrát. Při prvním průchodu má i-tý KPG obvod na vstupu a_i a b_i a na výstupu x_i , které pošle do prefixového obvodu. Při druhém průchodu funguje i-tý KPG obvod jako sčítač (respektive jako jeho část počítající paritu), na vstupu má a_i , b_i a y_i , které přijde z prefixového obvodu (s tím že hodnoty k a g jsou interpretovány jako 0 a1) a na výstupu má s_i = parita(a_i , b_i , y_i).

Čili zbývá dodělat paralelní prefixový obvod ...

35

Paralelní prefixový obvod

jako vstupy dostane carry statusy jednotlivých řádů, tj. x_0, x_1, \ldots, x_n a spočítá z nich hodnoty všech prefixů y_0, y_1, \ldots, y_n

```
označme [i, j] = x_i \otimes x_{i+1} \otimes ... \otimes x_j (a tedy [i, i] = x_i)
```

díky asociativitě platí $[i, k] = [i, j-1] \otimes [j,k]$ pro libovolné j takové, že $i < j \le k$

chceme spočítat $y_i = [0, i]$ pro všechna $i \in \{0, 1, ..., n\}$

paralelní prefixový obvod sestává pouze z obvodů realizujících carry status operátor \otimes

obvod má topologii úplného binárního stromu (zde potřebujeme aby n byla mocnina 2):

- v listech stromu jsou vstupy x₁ až x_n a v kořeni je vstup x₀
- při průchodu od listů ke kořeni se počítá pro každý vnitřní uzel (reprezentující interval od i do k), jehož levý syn reprezentuje interval od i do j-1 (a tedy má hodnotu [i, j -1]) a pravý syn interval od j do k (a tedy má hodnotu [j, k]) hodnota [i, k] = [i, j -1] \otimes [j,k]
- při průchodu od kořene k listům přijde do každého vnitřního uzlu (reprezentujícího interval od i do k) shora hodnota [0,i-1], kterou uzel pošle beze změny levému synovi (reprezentujícímu interval od i do j -1) a pravému synovi (reprezentujícímu interval od j do k) spočítá hodnotu $[0,j-1]=[0,i-1]\otimes [i,j-1]$
- výstupy y₀ až y_{n-1} jsou spočítány v listech a výstup y_n v kořeni
- velikost obvodu je $\Theta(n)$ a hloubka $\Theta(\log n)$

Třídy P a NP, převoditelnost problémů, NP úplnost

Úloha: pro dané zadání najít strukturu s danými vlastnostmi

Příkladv:

- v daném orientovaném grafu najdi cyklus
- vynásob dvě dané čtvercové matice

Optimalizační úloha: pro dané zadání najít optimální (většinou nejmenší nebo největší) strukturu s danými vlastnostmi

Příklady:

- v daném neorientovaném grafu najdi největší (počtem vrcholů) úplný podgraf (kliku)
- pro danou množinu úkolů najdi nejkratší rozvrh

Rozhodovací problém: pro dané zadání odpovědět ANO/NE

Příklady:

- existuje v daném neorientovanám grafu Hamiltonovská kružnice?
- je daná čtvercová matice regulární?

My se v následujícím omezíme jen na rozhodovací problémy, což lze (více méně) udělat bez újmy na obecnosti - v tom smyslu, že k většině (optimalizačních) úloh existuje "stejně těžký" rozhodovací problém.

<u>Definice</u> (vágní): Třída P je třída rozhodovacích problémů, pro které existuje (deterministický sekvenční) algoritmus běžící v polynomiálním čase (vzhledem k velikosti zadání), který správně rozhodne ANO/NE (který řeší daný problém).

- je daný orientovaný graf silně souvislý?
- obsahuje daný neorientovaný graf trojúhelník? (speciální případ "kliky")
- je daná matice regulární?

Nedeterministický algoritmus = algoritmus, který v každém svém kroku může volit z několika možností

Nedeterministický algoritmus řeší daný rozhodovací problém ⇔ pro každé kladné zadání problému (odpověď ANO) existuje posloupnost voleb vedoucí k tomu, že algoritmus odpoví ANO, pro žádné záporné zadání taková posloupnost voleb neexistuje.

<u>Definice</u> (vágní): Třída NP je třída rozhodovacích problémů, pro které existuje nedeterministický sekvenční algoritmus běžící v polynomiálním čase (vzhledem k velikosti zadání), který řeší daný problém.

Jiný model nedeterministického algoritmu: dopředu provede volby (do paměti zapíše vektor čísel) a pak už provádí jednotlivé kroky původního algoritmu deterministicky.

<u>Alternativní definice</u> (opět vágní): Rozhodovací problém patří do třídy NP, pokud pro každé jeho kladné zadání existuje (polynomiálně velký) certifikát, pomocí něhož lze v polynomiálním čase (deterministicky) ověřit, že zadání je skutečně kladné (že odpověď na dané zadání je skutečně ANO).

Příklady problémů ze třídy NP:

- KLIKA (úplný podgraf): Je dán neorientovaný graf G a číslo k.
 - Otázka: Existuje v G úplný podgraf velikosti alespoň k?
- HK (Hamiltonovská kružnice): Je dán neorientovaný graf G.
 - Otázka: Existuje v G Hamiltonovská kružnice?
- TSP (obchodní cestující): Je dán ohodnocený úplný neorientovaný graf G a číslo k.
 - Otázka: Existuje v G Hamiltonovská kružnice celkové délky nejvýše k?
- SP (součet podmnožiny): Jsou dána přirozená čísla a₁, a₂,, a_n, b.
 - Otázka: Existuje podmnožina čísel a_1, a_2, \dots, a_n , jejíž součet je přesně b?
- ROZ (rozvr. na paralel. strojích): Je dán počet úkolů, jejich délky, počet strojů a číslo k.
 Otázka: Existuje přípustný rozvrh délky nejvýše k?
- SAT (splnitelnost Booleovských formulí): Je dána formule na n 0-1 proměnných v KNF.
 Otázka: Existuje (pravdivostní) ohodnocení proměnných pro které má daná formule hodnotu 1?

Ukážeme, že HK \rightarrow TSP, SP \rightarrow ROZ a SAT \rightarrow KLIKA, kde A \rightarrow B znamená, že pokud existuje polynomiální algoritmus řešící B potom také existuje polynomiální algoritmus řešící A, neboli vyřešit B je alespoň tak "těžké" jako vyřešit A.

Převody (redukce) mezi rozhodovacími problémy

Nechť A,B jsou dva rozhodovací problémy. Říkáme, že A je polynomiálně redukovatelný na B, pokud existuje zobrazení f z množiny zadání problému A do množiny zadání problému B s následujícími vlastnostmi:

- 1. Nechť X je zadání problému A a Y zadání problému B takové, že Y = f(X). Potom je X kladné zadání problému A tehdy a jen tehdy, když je Y kladné zadání problému B.
- 2. Nechť X je zadání problému A. Potom je zadání f(X) problému B (deterministicky sekvenčně) zkonstruovatelné v polynomiálním čase vzhledem k velikosti X.

Poznámka: Z 2. také vyplývá, že velikost f(X) je polynomiální vzhledem k velikosti X.

NP-úplnost

<u>Definice</u>: Problém B je <u>NP-těžký</u> pokud pro libovolný problém A ze třídy NP platí, že A je polynomiálně redukovatelný na B.

<u>Definice</u>: Problém B je NP-úplný pokud 1) patří do třídy NP a 2) je NP-těžký.

<u>Důsledek 1</u>: Pokud je A NP-těžký a navíc je polynomiálně redukovatelný na B, tak je B také NP-těžký.

<u>Důsledek 2</u>: Pokud existuje polynomiální algoritmus pro nějaký NP-těžký problém, pak existují polynomiální algoritmy pro všechny problémy ve třídě NP.

Věta (Cook-Levin 1971): SAT je NP-úplný.

Aproximační algoritmy

Aprox. algoritmy jsou vhodné tam, kde je nalezení optimálního řešení "beznadějné" (časově příliš náročné), typicky u NP-těžkých optimalizačních úloh (optimalizačních verzí NP-úplných rozhodovacích problémů). Mají následující tři vlastnosti:

- 1. konstruují suboptimální řešení
- 2. poskytují odhad kvality zkonstruovaného řešení vzhledem k optimu
- 3. běží v polynomiálním čase (jinak nejsou zajímavé)

Příklad maximalizační úlohy (optimalizační verze KLIKY):

Pro daný neorientovaný graf najdi největší (počtem vrcholů) kliku (úplný podgraf).

Po aproximačním algoritmu chceme garanci typu $f(APROX) \ge \frac{3}{4} f(OPT)$, kde f(X) je v tomto případě počet vrcholů (tj. velikost kliky) v řešení X, OPT je optimální řešení a APROX je řešení vydané aproximačním algoritmem.

Příklad minimalizační úlohy (optimalizační verze ROZ):

Pro dané úkoly a daný počet strojů najdi nejkratší rozvrh.

Po aproximačním algoritmu chceme garanci typu f(APROX) ≤ 2 f(OPT).

<u>Definice</u>: Poměrová chyba aproximačního algoritmu je definována jako poměr (podíl) f(APROX) / f(OPT) pro minimalizační úlohy a f(OPT) / f(APROX) pro maximalizační úlohy. Relativní chyba je pak definována jako |f(APROX) – f(OPT)| / f(OPT).

Naivní aproximační algoritmus FRONTA pro optimalizační verzi ROZ: bere úkoly postupně podle jejich čísel a každý úkol vždy umístí na stroj, který je volný nejdříve.

<u>Značení</u>: OPT = optimální rozvrh, Q = rozvrh zkonstruovaný algoritmem FRONTA, délka(OPT) = o, délka(Q) = q

<u>Věta</u>: Pokud m je počet strojů, tak $q \le ((2m - 1) / m)o$ a tento odhad již nelze zlepšit.

<u>Důsledek</u>: Aproximační algoritmus FRONTA má poměrovou chybu 2.

<u>Důkaz</u>:

1. <u>Těsnost odhadu</u>: Pro každé m zkonstruujeme zadání, pro které platí v dokazované nerovnosti rovnost, a to následujícím způsobem

$$x_1 = x_2 = \dots = x_{m-1} = m-1$$
 (m-1 úkolů délky m-1)
 $x_m = x_{m+1} = \dots = x_{2m-2} = 1$ (m-1 úkolů délky 1)
 $x_{2m-1} = m$ (1 úkol délky m)

Platnost nerovnosti: Nechť j je úkol končící jako poslední v rozvrhu Q (končící v čase
q) a nechť t je okamžik zahájení úkolu j. Potom žádný procesor nemá prostoj před
časem t a platí mq ≤ (2m – 1)o.

<u>Lepší aproximační algoritmus USPOŘÁDANÁ FRONTA pro optimalizační verzi ROZ</u>: pracuje stejně jako FRONTA, ale na začátku úkoly setřídí do nerostoucí posloupnosti podle jejich délek.

Značení: OPT = optimální rozvrh,

U = rozvrh zkonstruovaný algoritmem USPOŘÁDANÁ FRONTA, délka(OPT) = o, délka(U) = u

<u>Věta</u>: Pokud m je počet strojů, tak u ≤ ((4m - 1) / 3m)o a tento odhad již nelze zlepšit.

<u>Důsledek</u>: Aproximační algoritmus USPOŘÁDANÁ FRONTA má poměrovou chybu 4/3.

<u>Důkaz</u>: <u>Těsnost odhadu</u>: Pro každé liché m zkonstruujeme zadání, pro které platí v dokazované nerovnosti rovnost, a to následujícím způsobem

$$x_1 = x_2 = 2m-1$$
 (2 úkoly délky 2m-1)

$$x_3 = x_4 = 2m-2$$
 (2 úkoly délky 2m-2)

$$x_{2m-3} = x_{2m-2} = m+1$$
 (2 úkoly délky m+1)
 $x_{2m-1} = x_{2m} = x_{2m+1} = m$ (3 úkoly délky m)

<u>Lemma</u>: Pokud pro všechny úkoly platí $x_i > 1/30$ pak u = 0.

<u>Dokončení důkazu</u>: Nechť j je úkol končící jako poslední v rozvrhu U (končící v čase u). Pokud $x_j > 1/3o$ tak použijeme Lemma, v opačném případě je důkaz 43 velmi podobný jako pro algoritmus FRONTA.

Pravděpodobnostní (randomizované) algoritmy

pravděpodobnostní algoritmus dělá (na rozdíl od deterministického algoritmu) náhodné kroky, např. k některým krokům používá hodnoty získané z generátoru náhodných čísel

tím pádem dvě různá spuštění téhož pravděpodobnostního algoritmu na stejných datech mají (s velkou pravděpodobností) různý průběh

pravděpodobnostních algoritmů je mnoho typů, zde zmíníme jen dva a to algoritmy typu Las Vegas a typu Monte Carlo

Algoritmy typu Las Vegas

výsledek je vždy správný, náhodnost ovlivňuje pouze dobu běhu algoritmu, tj. po jaké cestě se algoritmus ke správnému výsledku dobere

<u>Příklad</u>: randomizovaný QuickSort – od deterministické verze se liší náhodnými výběry pivota při každém dělení posloupnosti, což poskytuje následující výhody

- dává dobrý průměrný čas (tj. O(n log n)) i v případě, že data na vstupu nejsou náhodné permutace – žádný vstup není apriori špatný (pro každý deterministický výběr pivota existují apriori špatné vstupy)
- může být spuštěn paralelně v několika kopiích, výsledek je získán z kopie, kde výpočet skončí nejdříve (pro deterministickou verzi nemá takový postup žádný smysl)

45

Algoritmy typu Monte Carlo

náhodnost ovlivňuje jak dobu běhu, tak správnost výsledku: algoritmus může udělat chybu, ale pouze jednostranně (u odpovědí ANO/NE) a s omezenou pravděpodobností

Příklad: Rabin-Millerův algoritmus na testování prvočíselnosti

Úloha: pro zadané přirozené číslo n (rychle) rozhodnout zda je n prvočíslo

Trocha teorie (Malá) Fermatova věta (bez důkazu):

Nechť p je prvočíslo. Potom $\forall k \in \{1,2, ..., p-1\}$ platí $k^{p-1} \equiv 1 \pmod{p}$

<u>Myšlenka</u>: pokud n není prvočíslo, tak zkusíme (náhodně) najít "svědka" k, porušujícího $k^{n-1} \equiv 1 \pmod{n}$, který "dosvědčuje", že n je opravdu číslo složené (není to prvočíslo)

<u>Problém</u>: pro některá složená čísla je svědků příliš málo, takže je "příliš malá pravděpodobnost, že nějakého svědka (náhodně) vybereme.

<u>Definice</u>: Nechť T je množina dvojic přirozených čísel, kde $(k,n) \in T$ pokud 0 < k < n a je splněna alespoň jedna z následujících dvou podmínek:

```
1. neplatí k^{n-1} \equiv 1 \pmod{n},
```

2. existuje i takové, že m = $(n-1) / 2^i$ je přirozené číslo a platí $1 < NSD(k^{m-1}-1, n) < n$

Věta 1: Číslo n je složené tehdy a jen tehdy, když existuje k takové, že $(k,n) \in T$.

<u>Věta 2</u>: Nechť n je složené číslo. Pak existuje alespoň (n-1)/2 takových čísel k, pro které platí $(k,n) \in T$.

Rabin-Miller(n); for i:=1 to počet do k_i:= náhodné přirozené číslo z intervalu [1,n-1]; if (k_i,n) ∈ T then Report (n je složené);

Report (n je prvočíslo)

Pokud Rabin-Miller(n) rozhodne, že n je složené, tak je to zaručeně správný výsledek (byl nalezen "svědek"), pokud Rabin-Miller(n) rozhodne, že n je prvočíslo, tak se může jednat o chybu, ale pouze v případě, že všechna vybraná k_i byli "ne-svědci" pro složené číslo n, což ale může (díky Větě 2) nastat nejvýše s pravděpodobností

P(chyba) ≤ (1/2)počet

pokud jsou výběry jednotlivých k_i vzájemně nezávislé

Abort:

Vlastnosti algoritmu:

- zvyšováním počtu iterací (počtu testovaných k_i) lze dostat libovolně malou (předem zvolenou) pravděpodobnost chyby
- jednotlivé iterace (testy pro různá k_i) lze provádět paralelně

<u>Časová složitost:</u>

každá iterace trvá jen polynomiálně vzhledem k délce zápisu čísla n (tj. k délce vstupu), k tomu je ovšem potřeba ukázat, že test zda $(k_i,n) \in T$ je možno provést v čase polynomiálním v log n, což není triviální (je nutné mít další znalosti z teorie čísel) 46

Kryptografie s veřejným klíčem (asymetrickou šifrou)

- každý účastník X má svůj veřejný klíč PX a soukromý klíč SX
- SX je znám pouze X, veřejný klíč PX může X sdělit všem s kterými komunikuje, nebo může být dokonce zveřejněn ve veřejně dostupném seznamu klíčů (třeba na webu)
- oba klíče specifikují funkce, které lze aplikovat na jakoukoli zprávu: tedy pokud D je množina všech konečných posloupností bitů (množina všech možných zpráv), tak obě funkce musí být prosté funkce zobrazující D na D (tj. jsou to permutace množiny D)
- funkci specifikovanou soukromým klíčem SX značíme SX() a funkci specifikovanou veřejným klíčem PX značíme PX(), přičemž předpokládáme, že každá z těchto funkcí je efektivně vyčíslitelná pokud známe příslušný klíč
- funkce SX() a PX() musí tvořit vzájemně inverzní pár funkcí pro každou zprávu (konečnou posloupnost bitů) M tedy musí platit SX(PX(M)) = M a PX(SX(M)) = M.
- bezpečnost šifry stojí a padá s tím, že nikdo kromě účastníka X není schopen v "rozumném" čase spočítat SX(M) pro jakoukoli zprávu M, což znamená, že
 - 1. účastník X musí držet klíč SX v absolutním bezpečí před vyzrazením
 - funkce SX() nesmí být efektivně vyčíslitelná na základě znalosti PX (a schopnosti efektivně vyčíslit funkci PX()), což je hlavní obtíž při návrhu systému šifrování s veřejným klíčem

Předpokládejme, že máme 2 účastnice: A (Alici) a B (Barboru) s klíči SA, PA, SB a PB

Posílání zašifrované zprávy a její rozšifrování

Barbora chce poslat Alici zašifrovanou zprávu M:

- Barbora si opatří Alicin veřejný klíč PA (přímo od Alice či z veřejného seznamu klíčů)
- Barbora spočítá zašifrovaný text C = PA(M) a pošle ho Alici
- Alice na C aplikuje svůj soukromý klíč SA, tedy spočítá SA(C) = SA(PA(M)) = M
- Pokud C zachytí někdo jiný než Alice, nemá šanci získat M, protože neumí efektivně spočítat SA(C).

Posílání autentizované a podepsané (nešifrované) zprávy

Alice chce odpovědět Barboře tak, aby Barbora měla jistotu, že odpověď Q přichází od Alice a že text odpovědi nebyl pozměněn:

- Alice spočítá svůj digitální podpis q pro zprávu Q pomocí svého soukromého klíče, tj. spočítá q = SA(Q) a pošle Barboře dvojici (Q,q) tj. zpráva Q odchází nešifrovaně
- Barbora spočítá PA(g) = PA(SA(Q)) = Q a porovná to s došlou zprávou Q
- Pokud se obě zprávy zcela shodují, má Barbora jistotu, že zpráva přichází od Alice a nebyla cestou pozměněna
- Pokud se zprávy liší, tak buď je podpis q falešný (nebyl vytvořen funkcí SA()) nebo je podpis pravý ale nezašifrovaná zpráva Q byla cestou pozměněna

Posílání autentizované a podepsané zašifrované zprávy

Alice chce poslat Barboře zprávu M tak, aby Barbora měla jistotu, že M přichází od Alice a že text M nebyl pozměněn. Navíc Alice chce, aby si M mohla přečíst pouze Barbora a nikdo jiný.

- Alice spočítá svůj digitální podpis pro M, tedy spočítá m = SA(M)
- Alice zašifruje dvojici (M,m) pomocí Barbořina veřejného klíče, tedy spočítá zašifrovaný text C = PB(M,m) a pošle C Barboře
- Barbora rozšifruje C pomocí svého soukromého klíče, tedy spočítá SB(C) = (M,m)
- Barbora ověří platnost Alicina podpisu a autenticitu M pomocí Alicina veřejného klíče, tj. spočítá PA(m) a porovná to s M při neshodě Barbora ví, že buď bylo C cestou změněno (úmyslně či přenosovou chybou) nebo C nepřichází od Alice.

Hybridní šifrování

Pokud je zpráva M, kterou chce Barbora poslat Alici, velmi dlouhá a výpočet C = PA(M) a následně M = SA(C) by trval příliš dlouho, je možné použít šifrování s veřejným klíčem v kombinaci s nějakou symetrickou šifrou K, která šifruje zprávy rychle:

- Barbora spočítá C = K(M), což je opět dlouhá posloupnost bitů, k tomu spočítá PA(K), což je krátká posloupnost bitů (ve srovnání s M a PA(M)) a pošle (C,PA(K)) Alici
- Alice rozšífruje PA(K) pomocí svého SA, takže dostane K, pomocí kterého rozšífruje C a tak získá M

Hybridní autentizace a podepisování

Pro dlouhou zprávu M je také časově náročné počítat digitální podpis m = SA(M). Zde si vypomůžeme (veřejně známou) hashovací funkcí h, která má následující dvě vlastnosti:

- 1. I pro dlouhé M lze h(M) spočítat velmi rychle, typicky je h(M) krátký (např. 128 bitový) otisk (fingerprint) zprávy M.
- 2. Je výpočetně velmi obtížné (v rozumném čase nemožné) najít k M jinou zprávu Q takovou, aby platilo h(M) = h(Q)

Pokud chce Alice podepsat dlouhou zprávu posílanou Barboře, může postupovat takto:

- Alice spočítá otisk h(M) zprávy M, udělá z něj digitální podpis m = SA(h(M)) a pošle Barboře dvojici (M,m)
- Barbora obdrží M a také spočítá otisk h(M) který poté porovná s rozšifrovaným Aliciným digitálním podpisem PA(m) = PA(SA(h(M))). Pokud byla M cestou změněna, tak dojde k neshodě, protože díky vlastnosti 2 je těžké pozměnit M tak, aby se její otisk nezměnil.

Certifikační autority

Pokud si Alice pořizuje Barbořin veřejný klíč z veřejně dostupného seznamu (nebo jí ho Barbora posílá po síti), jak může mít jistotu, že nejde o podvrh? Pokud by byl klíč podvržen a následné zprávy modifikovány nebo podvrhovány stejným člověkem, který podvrhl svůj klíč jako Barbořin, tak jejich nepravost nelze zjistit (protože daný člověk bude mít k podvrženému veřejnému klíči i odpovídající soukromý klíč). Řešení:

- Existuje certifikační autorita Z, jejíž veřejný klíč PZ má každý účastník (tedy i Alice) nainstalován u sebe (například přišel na CD s šifrovacím softwarem).
- Barbora pak má od autority Z vydán certifikát ve tvaru C = "Barbořin klíč je PB" podepsaný autoritou Z, tedy dvojici (C, SZ(C)) – toto může mít Barbora také již od koupě šifrovacího softwaru, nebo certifikát získá jinou bezpečnou cestou
- Tuto dvojici (C, SZ(C)) připojí Barbora ke každé podepisované zprávě, takže Alice (i kdokoli jiný) zjistí pomocí veřejného klíče PZ, že C bylo opravdu vydáno autoritou Z, a že tedy PB opravdu je Barbořin veřejný klíč

RSA (Rivest, Shamir, Adelman) šifra

pro vysvětlení RSA potřebujeme řadu pojmů a tvrzení z teorie čísel

Věta: Nechť a,b jsou přirozená čísla. Pak NSD(a,b) je nejmenší kladný prvek množiny

$$L = \{ax + by \mid x,y \in Z\}$$

<u>Důsledek</u>: Nechť a,b jsou přirozená čísla. Pokud d je přirozené číslo, které dělí a i b, tak d dělí také NSD(a,b).

Věta: Nechť a,b jsou přirozená čísla, kde b>0. Pak NSD(a,b) = NSD(b, a mod b).

EUCLID(a,b)

if b=0 then Return(a)

else Return(EUCLID(b, a mod b))

51

<u>Lemma</u>: Nechť $a > b \ge 0$ a EUCLID(a,b) udělá $k \ge 1$ rekurzivních kroků. Pak $a \ge F(k+2)$ a $b \ge F(k+1)$, kde F(i) je i-té Fibonacciho číslo.

<u>Důsledek</u> (Lamého věta): Nechť $a > b \ge 0$ a $F(k) \le b < F(k+1)$. Pak EUCLID(a,b) udělá nejvýše k - 1 rekurzivních kroků.

Věta (bez Dk): $F(k) = \Theta(\phi^k)$, kde $\phi = (1+\sqrt{5})/2$ (což je tzv. "zlatý řez").

<u>Důsledek</u>: Nechť $a > b \ge 0$ a $F(k) \le b < F(k+1)$. Pak EUCLID(a,b) udělá nejvýše $O(\log b)$ rekurzivních kroků.

<u>Pozorování</u>: Pokud a,b jsou dvě nejvýše t-bitová binární čísla, tak EUCLID(a,b) provede O(t) rekurzivních kroků a v každém z nich O(1) aritmetických operací na (nejvýše) t-bitových číslech, tj. $O(t^3)$ bitových operací, pokud předpokládáme, že každá aritmetická operace na t-bitových číslech potřebuje $O(t^2)$ bitových operací (což je snadné ukázat). EUCLID je tedy polynomiální algoritmus vzhledem k velikosti vstupu.

Euklidův algoritmus lze snadno rozšířit tak, aby počítal také koeficienty x,y, pro které NSD(a,b) = ax + by.

```
EXTENDED-EUCLID(a,b)
```

if b=0 then Return(a,1,0)

```
else (d',x',y') := EXTENDED-EUCLID(b, a mod b);

(d,x,y) := (d',y',x'-\lfloor a/b \rfloor y');

Return(d,x,y)
```

<u>Věta</u> (bez Dk): Nechť n > 1 a a < n jsou dvě nesoudělná přirozená čísla. Pak má rovnice $ax \equiv 1 \pmod{n}$, právě jedno řešení 0 < x < n (a pokud jsou a,n soudělná, tak nemá žádné řešení).

<u>Definice</u>: Řešení rovnice $ax \equiv 1 \pmod{n}$ značíme $(a^{-1} \mod n)$ a nazýváme multiplikativní inverz čísla a modulo n (aby existoval, tak musí být a,n nesoudělná).

Pozorování: (a-1 mod n) snadno získáme pomocí rozšířeného Euklidova algoritmu.

<u>Věta</u> (speciální důsledek tzv. "čínské věty o zbytcích" – bez Dk): Nechť a,b jsou nesoudělná přirozená čísla. Pak pro každá přirozená čísla x,y platí: $x \equiv y \pmod{ab}$ tehdy a jen tehdy, když $x \equiv y \pmod{a}$ a zároveň $x \equiv y \pmod{b}$.

<u>Věta</u> (malá Fermatova): Nechť p je prvočíslo. Pak \forall k∈{1,2, ...,p-1} platí k^{p-1} ≡1 (mod p).

Nyní máme vše co potřebujeme k definici a vysvětlení RSA:

- 1.Náhodně vyber dvě velká prvočísla p a q (např. každé s 200 binárními ciframi).
- 2. Spočítej n = pq (v uvedeném případě má n cca 400 binárních cifer).
- 3. Vyber malé liché číslo e, které je nesoudělné s číslem (p-1)(q-1).
- 4. Spočítej multiplikativní inverz d čísla e modulo (p-1)(q-1).
- 5. Zveřejni (e,n) jako veřejný RSA klíč a uschovej (d,n) jako soukromý RSA klíč.

<u>Věta</u> (korektnost RSA): Funkce $P(M) = M^e \mod n$ a $S(M) = M^d \mod n$ definují dvojici inverzních funkcí na množině všech zpráv, tj. na množině všech čísel v $Z_n = \{0,1,\ldots,n-1\}.$

Proč je RSA bezpečná?

Na základě (e,n) není (zatím) nikdo schopen spočítat d aniž by znal rozklad n = pq a tím pádem také číslo (p-1)(q-1). A faktorizace velkých čísel je výpočetně těžký problém.

Jak je RSA rychlá?

To, jak rychle lze spočítat P(M) a S(M) závisí na tom, jak rychle umíme počítat zbytek modulo n při umocňování, tj. jak rychle lze spočítat a^b mod n.

```
UMOCNI (a,b,n) {kde binární zápis čísla b je <b_k, ...,b_0>} c := 1; d := a mod n;
```

```
for i := k-1 downto 0 do

c := 2 \cdot c;

d := (d \cdot d) \mod n;

if b_i = 1 then c := c + 1;

d := (d \cdot a) \mod n;
```

Return(d)

<u>Časová složitost</u>: Pokud a,b jsou nejvýše t-bitová binární čísla, tak <u>UMOCNI</u> provede O(t) aritmetických operací na (nejvýše) t-bitových číslech, tj. $O(t^3)$ bitových operací, pokud předpokládáme, že každá aritmetická operace na t-bitových číslech potřebuje $O(t^2)$ bitových operací (což je snadné ukázat).